

Homework of Pattern classification

*Name: Xue Yuan — Student number: 202228015926034

Abstract—This document is about the first homework for Pattern classification by L^AT_EX.

I. QUESTION 1

请描述最小错误率贝叶斯决策的计算步骤（包含已知条件以及求解任务）；给出一种两类情形下的最小错误率贝叶斯决策规则。

已知条件:

1) 先验概率

$$P(\omega_i), \quad \sum_{i=1}^c P(\omega_i) = 1$$

2) 概率密度函数(条件概率) $P(\omega_i|x)$

求解任务:

如果观测到一个样本 x ,那么应该将其分到哪一类才最合理呢?

两类情形下的最小错误率贝叶斯决策规则:

if $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$, then $x \in \omega_1$;
otherwise $x \in \omega_2$

II. QUESTION 2

请描述最小风险贝叶斯决策的计算步骤（包含已知条件以及求解任务）；给出一种两类情形下的最小风险贝叶斯决策规则。

已知条件:

1) 先验概率

$$P(\omega_i), \quad \sum_{i=1}^c P(\omega_i) = 1$$

2) 概率密度函数(条件概率) $P(\omega_i|x)$

3) 决策空间包含 a 个决策 $\alpha_i, i=1,2,\dots,a$

4) 损失函数 $P(\lambda_i|\omega_j)$,表示当类别为 ω_j 所采取的决策 α_i 所引起的损失,简记为 λ_{ij} 。

求解任务:

如果观测到一个样本 x ,那么应该将其分到哪一类其风险最小?

两类情形下的最小风险贝叶斯决策规则:

$$R(\alpha_i | x) = E[\lambda(\alpha_i | \omega_j)] = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | x)$$

$i = 1, 2, \dots, a$; And if $R(\alpha_1 | x) < R(\alpha_2 | x)$, then $\alpha = \alpha_1$;
otherwise $\alpha = \alpha_2$

III. QUESTION 3

对于 c 类问题,假定各类条件概率密度函数均为多元正态分布。在最小错误率贝叶斯决策的框架下,请写出其判别函数;请分别指出在什么情况下可以获得最小距离分类器,在什么情况下可以得到线性判别函数。

最小错误率贝叶斯决策框架下的判别函数:

$$\begin{aligned} g_i(x) &= \ln(p(x|\omega_i)) + \ln(P(\omega_i)) \\ &= -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) \\ &\quad - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(|\Sigma_i|) + \ln(P(\omega_i)) \\ &\quad (i = 1, 2, \dots, a) \end{aligned}$$

最小距离分类器:

当样本的协方差矩阵相等且等于一常数,即 $\Sigma_i = \sigma^2 I, i=1,2,\dots,c$ 。且先验概率相等即: $P(\omega_i) = P(\omega_j)$,此时,判别函数可进一步简单化为:

$$g_i(x) = -\frac{1}{2\sigma^2} \|x - \mu_i\|_2^2$$

此时,要对样本 x 进行分类,只需要计算 x 到各类均值向量的欧氏距离平方,然后将归于距离最短的一类:

$$\arg \min_{i=1,2,\dots,c} \|x - \mu_i\|_2^2$$

这样的分类器我们称最小距离分类器

线性判别函数:

1) 与最小距离分类器的条件类似,当先验概率不相等即 $P(\omega_i) \neq P(\omega_j)$ 时,判别函数 $g_i(x)$ 可以写成:

$$\begin{aligned} g_i(x) &= -\frac{1}{2\sigma^2} (x - \mu_i)^T (x - \mu_i) + \ln(P(\omega_i)) \\ &= -\frac{1}{2\sigma^2} (x^T x - 2\mu_i^T x + \mu_i^T \mu_i) + \ln(P(\omega_i)) \end{aligned}$$

2) 由于每一类的判别函数均包含 $x^T x$,与下标 i 无关,因此可以进一步简化为线性判别函数:

$$\begin{aligned} g_i(x) &= \frac{1}{\sigma^2} \mu_i^T x - \frac{1}{2\sigma^2} \mu_i^T \mu_i + \ln(P(\omega_i)) = w_i^T x + w_{i0} \\ w_i &= \frac{1}{\sigma^2} \mu_i \quad w_{i0} = \ln(P(\omega_i)) - \frac{1}{2\sigma^2} \mu_i^T \mu_i \end{aligned}$$

IV. QUESTION 4

针对概率密度函数参数估计问题,请描述最大似然估计的计算步骤（包含已知条件以及求解任务）。

已知条件:

- 1) 假设每组样本都是从类条件概率具有形式 $P(x|\omega_i)$ 的总体中独立重复抽取出来的
- 2) 类条件概率函数 $P(x|\omega_i)$ 具有未知参数 θ ,参数 θ 表征了总体 X 的一种或几种特征(如均值或方差等)
- 3) 各类样本仅仅包含本类的分布信息,不同类别的参数 θ 相互独立

求解任务:

给定样本集 $D = \{X_1, X_2, \dots, X_n\}$, 要找到一个条件概率最大的参数 θ , 即求:

$$\arg \max_{\theta} P(D|\theta)$$

计算步骤:

- 1) 从总体中独立重复的抽取样本得到样本集 $D = \{X_1, X_2, \dots, X_n\}$
- 2) 视每一次抽样为一个概率事件, 那么, 独立的获得 n 个样本的联合概率(称似然函数 $l(\theta)$)为:

$$l(\theta) = P(D|\theta) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\theta) = \prod_{i=1}^n p(\mathbf{x}_i|\theta)$$

它描述了在不同参数取值下取得当前样本的可能性。为了计算方便, 我们有时也会采用对数形式下的似然函数 $H(\theta)$:

$$H(\theta) = \ln(l(\theta)) = \ln \prod_{i=1}^n p(\mathbf{x}_i|\theta) = \sum_{i=1}^n \ln(p(\mathbf{x}_i|\theta))$$

- 3) 当我们从样本空间中选取到的参数 $\hat{\theta}$, 使得似然函数 $l(\theta)$ (或 $H(\theta)$) 取最大值时, 我们便称 $\hat{\theta}$ 为参数 θ 的最大似然估计量
- 4) 确定了似然函数以后, 通过对似然函数求导(多维情况下求梯度), 我们能够得到参数 θ 的最大似然估计值

V. QUESTION 5

针对样本的类条件概率密度函数估计问题, 请描述贝叶斯估计的计算步骤(包含已知条件以及求解任务)。

已知条件:

贝叶斯估计与最大似然估计在整体上几乎一致, 只是在待估参数的处理上存在差异。贝叶斯估计认为, 待估参数是一个随机变量, 而样本 D 是固定的(一经取得), 需要对待估参数的分布进行重点估计。

求解任务:

- 1) 通过先验概率 $p(\theta)$ (没有掌握数据时, 参数 θ 的分布情况) 和样本分布估计后验概率 $P(\theta|D)$ (掌握了一定量的数据后参数 θ 的分布情况)
- 2) 不断学习使得后验概率 $P(\theta|D)$ 取最大
- 3) 通过最大 $P(\theta|D)$ 结合样本分布情况估计总体的概率分布 $P(x|D)$

计算步骤:

- 1) 由贝叶斯公式, 后验概率 $P(\theta|D)$ 可以表示为:

$$P(\theta|D) = \frac{P(D|\theta)p(\theta)}{p(D)}$$

- 2) 由全概率公式:

$$p(D) = \int_{\theta} p(D|\theta)p(\theta)d\theta$$

可以得到:

$$P(D|\theta) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\theta) = \prod_{i=1}^n p(\mathbf{x}_i|\theta)$$

- 3) 带入1)中, 有贝叶斯参数估计中的后验概率密度函数:

$$P(\theta|D) = \frac{P(D|\theta)p(\theta)}{\int_{\theta} \prod_{i=1}^n p(\mathbf{x}_i|\theta)p(\theta)d\theta} = \alpha \prod_{i=1}^n p(\mathbf{x}_i|\theta)p(\theta)$$

- 4) 考虑边际分部, 可以得到:

$$\begin{aligned} P(x|D) &= \int_{\theta} p(x, \theta|D) d\theta \\ &= \int_{\theta} \frac{P(x, \theta, D)}{p(D)} d\theta \\ &= \int_{\theta} \frac{p(x|\theta)p(\theta, D)}{p(D)} d\theta \\ &= \int_{\theta} p(x|\theta)p(\theta|D) d\theta \\ &= \int_{\theta} p(x|\theta)p(\theta|D) d\theta \end{aligned}$$

考虑总体自身的分布情况, 我们就完成了通过样本估计后验概率, 再由后验概率估计总体概率分布的任务(Fig1展示了这一过程)。




Fig. 1: Flowchart of the estimation process.

VI. QUESTION 6

请指出最大似然估计和贝叶斯估计的不同之处?

他们之间最大的差异在于对待估参数的认识:

最大似然估计认为, 待估参数是存在的, 同时, 假定样本 D 是随机的。可以通过总体抽取出的样本, 对待估参数进行准确估计。

贝叶斯估计则认为, 参数是随机变量, 而样本 D 是固定的。由于样本是固定的, 因此重点研究待估参数的分布。